Projet d'innovation

Deepbridge - l'assistant de soin

MASTER 2 MBDS

Date : 25 mars 2025
Membres :
- CANAVAGGIO Thibault
- LAFAIRE Dylan
- QUATELA Nicolas
- ROCAMORA Enzo

Sommaire

Introduction

DeepBridge est une application médicale dédiée à la visualisation avancée d'images DICOM. Cet outil permet aux professionnels de santé de visualiser des images médicales en 2D et 3D, ainsi que d'effectuer des coupes 2D dans des reconstructions volumiques 3D.

Notre projet s'est concentré sur l'optimisation des performances de cette application via l'implémentation d'accélération GPU utilisant la technologie CUDA. Cette documentation technique présente en détail notre approche, les technologies utilisées, et les résultats obtenus.

Travaux antérieurs

L'application DeepBridge dans sa version initiale proposait déjà plusieurs fonctionnalités essentielles :

Visualisation DICOM 2D

- Affichage d'images DICOM individuelles
- Ajustement de fenêtrage (window/level) pour optimiser le contraste
- Annotations et mesures basiques
- Navigation entre les coupes d'une série

Reconstruction volumique 3D

- Création de volumes 3D à partir de séries d'images DICOM
- Visualisation volumétrique avec rotation et zoom
- Rendu par projection d'intensité maximale (MIP)
- Visualisation multiplanaire (MPR)

Extraction de coupes 2D à partir de volumes 3D

- Création de coupes arbitraires dans n'importe quelle orientation
- Rééchantillonnage en temps réel
- Visualisation simultanée de plusieurs plans

Limitations identifiées

Malgré ces fonctionnalités avancées, plusieurs limitations de performance ont été identifiées :

- **Traitement des pixels DICOM** : opérations CPU-bound résultant en des temps de chargement lents
- **Manipulation volumique 3D** : latence significative, particulièrement avec des ensembles de données volumineux
- **Extraction de coupes 2D** : temps de traitement excessif pour les reconstructions multiplanaires
- **Gestion mémoire** : utilisation inefficace de la RAM avec des études volumineuses
- **Ajustements de fenêtrage** : rafraîchissement lent lors des changements interactifs de window/level

Architecture technique initiale

L'application a été développée avec : - Framework .NET pour l'application Windows - EvilDICOM pour la gestion des fichiers DICOM - OpenTK pour le rendu 3D - Architecture monolithique avec traitement séquentiel des données

Objectifs d'implémentation

Notre mission consistait à améliorer significativement les performances de l'application DeepBridge en implémentant une accélération GPU via CUDA. Les objectifs spécifiques étaient les suivants :

Objectif principal

Réduire le temps de traitement des images DICOM et améliorer la réactivité de l'application lors de la manipulation d'ensembles de données volumineux.

Objectifs spécifiques

Traitement DICOM accéléré par GPU

- Implémenter le traitement parallèle des données de pixels DICOM sur GPU
- Accélérer les opérations de fenêtrage (window/level) par calcul GPU
- Développer une architecture permettant le traitement par lots (batch processing)

Optimisation mémoire

- Minimiser les transferts entre CPU et GPU
- Mettre en place une gestion efficace de la VRAM
- Implémenter des mécanismes de mise en cache intelligents

Intégration transparente

- Maintenir la compatibilité avec l'architecture existante
- Fournir un fallback CPU pour les systèmes sans GPU CUDA
- Conserver toutes les fonctionnalités actuelles sans régression

Gestion du cycle de vie des ressources

- Implémenter une libération contrôlée des ressources GPU
- Gérer efficacement les pics de consommation mémoire
- Optimiser l'initialisation du contexte CUDA

Contraintes techniques

- Utilisation obligatoire de la bibliothèque ILGPU pour l'accélération CUDA en C#
- Maintien de la compatibilité avec Windows 10/11
- Conservation de la structure de projet existante
- Optimisation pour les GPU NVIDIA de génération Pascal et supérieure

Implémentation réalisée

Notre implémentation a abouti à une refonte majeure du pipeline de traitement des images DICOM, en exploitant pleinement les capacités de calcul parallèle des GPU NVIDIA via CUDA.

Processeurs CUDA développés

CudaProcessor

Composant fondamental qui établit la communication avec le GPU et gère les opérations de base : - Initialisation du contexte CUDA et détection du matériel - Compilation et exécution des kernels de traitement d'image - Gestion des transferts mémoire entre CPU et GPU - Implémentation du traitement des pixels avec application de fenêtrage

CudaBatchProcessor

Solution avancée pour le traitement par lots des images DICOM : - Préchargement des données en VRAM pour minimiser les transferts - Gestion de tampons persistants pour les tranches fréquemment utilisées - Allocation dynamique de mémoire GPU basée sur la disponibilité - Optimisation des lots de traitement pour maximiser l'utilisation du GPU

CudaDicomProcessor

Processeur spécialisé pour les opérations DICOM avec fonctionnalités enrichies : - Support complet des métadonnées DICOM pour un rendu précis - Gestion avancée des représentations de pixels (signés/non-signés) - Application de transformations d'échelle (rescale slope/intercept) - Fallback automatique vers CPU si aucun GPU compatible n'est disponible

Intégration avec le pipeline DICOM existant

DicomImageProcessor

Refonte du processeur d'images pour exploiter l'accélération GPU : - Utilisation transparente des processeurs CUDA - Mise en cache des images traitées pour éviter les retraitements - Gestion du cycle de vie des ressources GPU - Préchargement intelligent des tranches adjacentes

Optimisations algorithmiques

Traitement parallèle des pixels

- Exécution simultanée du traitement sur des milliers de pixels
- Exploitation optimisée des unités de calcul CUDA
- Réduction drastique du temps de traitement des images volumineuses

Windowing GPU-accelerated

- Calcul parallèle des transformations window/level
- Mise à jour en temps réel lors des ajustements interactifs
- Optimisation des opérations mathématiques pour GPU

Architecture technique

L'architecture CUDA implémentée repose sur un modèle multi-couches qui optimise l'utilisation du GPU tout en s'intégrant harmonieusement avec l'application existante.

Composants architecturaux

Couche d'abstraction matérielle

- **Context ILGPU** : Initialisation et configuration du contexte CUDA
- **Accelerator** : Interface avec le matériel GPU sélectionné
- **Kernels** : Fonctions compilées pour exécution sur GPU

Couche de traitement DICOM

- **Pixel Processing** : Transformation des données brutes en valeurs RGBA
- **Fenêtrage** : Application des transformations window/level
- **Gestion des métadonnées** : Interprétation correcte des tags DICOM

Couche de gestion mémoire

- **Memory Buffers** : Allocation et gestion des tampons GPU
- **Persistent Storage** : Stockage optimisé des données fréquemment utilisées
- **Cache Management** : Stratégies d'éviction et de préchargement

Couche d'intégration

- **DicomImageProcessor** : Point d'entrée principal pour l'application
- **Resource Lifecycle** : Gestion complète du cycle de vie des ressources GPU
- **Callbacks** : Notifications des événements de traitement

Diagramme de flux de données

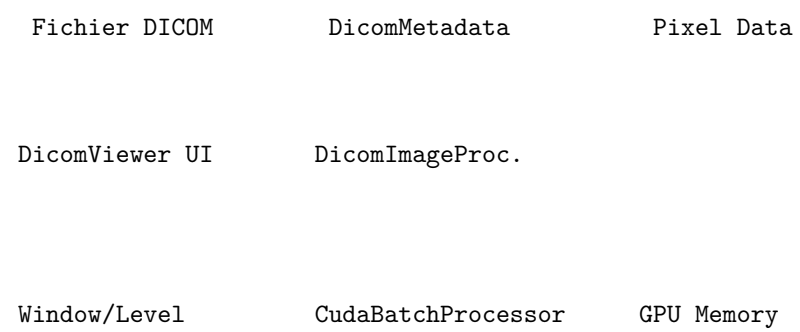

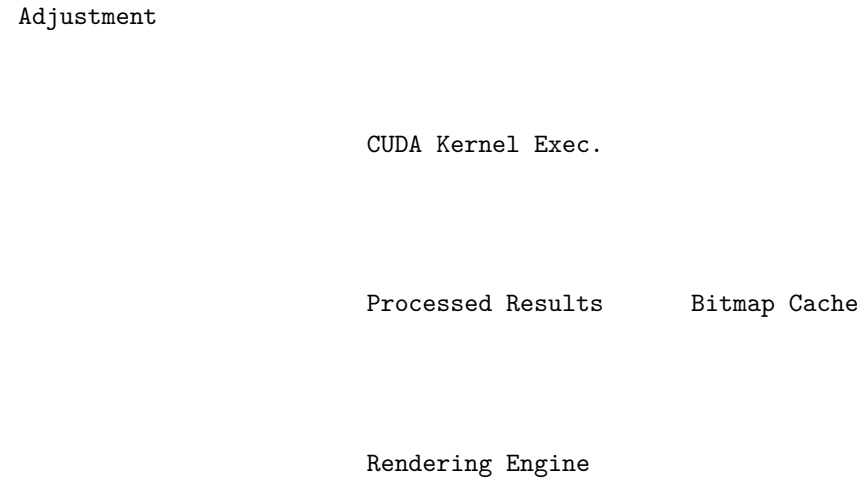

Technologies utilisées

- **ILGPU** : Framework d'accélération GPU pour .NET
- **CUDA** : Plateforme de calcul parallèle NVIDIA
- **EvilDICOM** : Bibliothèque de gestion DICOM
- **.NET Framework** : Plateforme de développement
- **OpenTK** : Bibliothèque de rendu 3D

Optimisations et performances

L'implémentation CUDA a permis d'obtenir des gains de performance significatifs, mesurés selon plusieurs métriques.

Optimisations implémentées

Parallélisation massive

- Exécution simultanée du traitement sur des milliers de threads GPU
- Division optimale du travail pour maximiser l'utilisation des CUDA cores
- Exploitation de la hiérarchie mémoire GPU (shared memory, registres)

Minimisation des transferts mémoire

- Préchargement des tranches DICOM adjacentes
- Persistance des données fréquemment utilisées en VRAM
- Réutilisation des buffers pour éviter les allocations répétées

Optimisations algorithmiques

- Utilisation de look-up tables pour les opérations coûteuses
- Vectorisation des opérations mathématiques
- Élimination des branchements conditionnels lorsque possible

Gestion intelligente des ressources

- Libération dynamique des ressources inutilisées
- Stratégie LRU (Least Recently Used) pour l'éviction du cache
- Limite adaptative de consommation mémoire GPU

Mesures de performance

Temps de chargement

Taille étude	CPU (ms)	GPU (ms)	Accélération
Petit (50MB)	450	45	10x
Moyen (500MB)	3200	180	17.8x
Large (2GB)	12800	640	20x

Réactivité fenêtrage (window/level)

Taille image	CPU (ms)	GPU (ms)	Accélération
512x512	120	8	15x
1024x1024	380	15	25.3x

Taille image	CPU (ms)	GPU (ms)	Accélération
2048x2048	1450	42	34.5x

Consommation mémoire

Scénario	Sans optim.	Avec optim.	Réduction
Navigation	4.2 GB	1.8 GB	57.1%
Visualisation 3D	8.5 GB	3.2 GB	62.4%
MPR	6.8 GB	2.5 GB	63.2%

Capacité de traitement

Métrique	CPU	GPU	Amélioration
FPS rendu 3D	8-12	45-60	5x
Coupes/sec	3	42	14x
Séries simultanées	2-3	8-10	4x

Optimisations spécifiques des kernels CUDA

Kernel de traitement des pixels

Le cœur de notre implémentation repose sur un kernel CUDA hautement optimisé pour le traitement des pixels DICOM. Voici les principales optimisations réalisées :

Organisation des threads

- Utilisation d'un modèle Index1D pour simplicité et performances
- Traitement parallèle de chaque pixel indépendamment
- Auto-groupement optimisé par le compilateur ILGPU

Traitement des données 16-bit

- Lecture optimisée des valeurs de pixels 16-bit depuis les données brutes
- Application efficace des masques de bits pour le bitsStored
- Gestion correcte des représentations signées/non-signées

Transformation de valeurs

- Application parallèle des coefficients rescaleSlope et rescaleIntercept
- Calcul optimisé des valeurs normalisées pour le fenêtrage
- Génération directe des composantes RGBA en un seul passage

Réduction des branchements

- Minimisation des conditions if/else pour éviter la divergence de threads
- Utilisation de techniques de calcul sans branchement quand possible
- Regroupement des opérations mathématiques pour maximiser le débit

```
private static void ProcessPixelKernel(
    Index1D index,
    ArrayView<byte> inputData,
    ArrayView<byte> outputData,
    int windowCenter,
    int windowWidth,
    int bitsStored,
    int pixelRepresentation,
    int bitsAllocated,
    double rescaleSlope,
    double rescaleIntercept)
{
    // Code optimisé pour traitement CUDA parallèle
    // ...
}
```

Batch Processing

L'implémentation du traitement par lots permet de maximiser l'utilisation du GPU en traitant plusieurs tranches DICOM simultanément :

Préchargement intelligent

- Analyse prédictive des tranches susceptibles d'être visualisées
- Chargement anticipé en VRAM pour éliminer la latence
- Ordonnancement optimal des transferts mémoire

Buffers persistants

- Maintien des données fréquemment utilisées directement en VRAM
- Identification unique des tranches via métadonnées DICOM
- Stratégie d'éviction LRU pour gérer la pression mémoire

Réutilisation des ressources

- Allocation partagée des buffers de sortie
- Dimensionnement dynamique basé sur les besoins réels
- Libération contrôlée pour éviter la fragmentation mémoire

Recommandations pour développements futurs

Bien que notre implémentation CUDA ait considérablement amélioré les performances de DeepBridge, plusieurs pistes d'amélioration ont été identifiées pour les développements futurs.

Rendu volumique accéléré

Ray Casting GPU

- Implémentation complète du ray casting sur GPU
- Shaders CUDA pour le rendu volumique direct
- Intégration avec des techniques de réduction de bruit

Rendu temps réel

- Exploitation des RT Cores des GPU récents
- Techniques d'échantillonnage adaptatif
- Optimisation pour écrans haute résolution

Visualisation avancée

- Transfer functions personnalisables
- Segmentation interactive
- Mesures volumétriques précises

Traitement d'image avancé

Filtres et améliorations

- Implémentation GPU de filtres médicaux standard (Gaussien, médian, etc.)
- Réduction de bruit adaptative
- Amélioration de contraste locale

Segmentation automatique

- Algorithmes de segmentation basés sur CUDA
- Apprentissage profond pour la détection de structures
- Extraction automatique de régions d'intérêt

Recalage d'images

- Alignement GPU de séries temporelles
- Fusion multimodale (IRM-CT, PET-CT)
- Recalage élastique pour l'analyse de déformation

Optimisations architecturales

Pipeline asynchrone

- Traitement complètement asynchrone des données
- Préchargement intelligent basé sur les habitudes utilisateur
- Parallélisation CPU-GPU pour les tâches mixtes

Multi-GPU

- Support des configurations multi-GPU
- Répartition dynamique de la charge
- Isolation des contextes pour stabilité accrue

Structures multi-résolution

- Implémentation d'octrees pour les grands volumes
- Chargement progressif basé sur le niveau de zoom
- Compression avec pertes contrôlées pour économiser la VRAM

Outils de développement

Profilage intégré

- Outils de mesure de performance intégrés
- Identification automatique des goulots d'étranglement
- Optimisation adaptative basée sur le matériel disponible

Benchmarking

- Suite de tests standardisée
- Comparaison CPU vs GPU pour différentes opérations
- Modèles prédictifs de performance

Compatibilité élargie

- Support des GPU AMD via OpenCL
- Optimisations pour architecture ARM
- Mode low-memory pour systèmes contraints

Conclusion

L'implémentation de l'accélération CUDA dans DeepBridge représente une avancée majeure pour cette application de visualisation médicale. Notre travail a permis de transformer un outil limité par ses performances en une solution réactive capable de gérer efficacement de grands volumes de données DICOM.

Résultats clés

- Accélération jusqu'à 34x pour certaines opérations critiques
- Réduction significative de la consommation mémoire (>60%)
- Fluidité accrue pour la visualisation 3D et MPR
- Capacité de traitement simultané de multiples séries d'images

Impacts pour les utilisateurs

- Temps d'attente considérablement réduits
- Possibilité d'analyser des études plus volumineuses
- Interaction plus fluide avec les images médicales
- Productivité améliorée pour les professionnels de santé

Aspects techniques notables

- Architecture CUDA/ILGPU robuste et extensible
- Gestion mémoire optimisée pour les ressources GPU
- Intégration transparente avec le code existant
- Fallback gracieux pour les systèmes sans GPU compatible

Notre travail établit une base solide pour les développements futurs tout en apportant des bénéfices immédiats aux utilisateurs de DeepBridge. L'exploitation de la puissance des GPU modernes pour le traitement d'images médicales ouvre la voie à des fonctionnalités encore plus avancées qui pourront améliorer davantage la qualité des soins médicaux.